

Relatório da atividade de classificação

Link dos códigos fonte: https://github.com/Cvtr-C/Trabalho_de_classificacao_de_folhas/tree/main

Aluno: Carlos Vitor Taleires Rodrigues

Data: 17/07/2026

1. Análise de dados do Flavia Dataset:

1.1. Quantidade total de imagens

A base de dados Flavia Dataset é composta por um total de 1.907 imagens, distribuídas uniformemente ao longo de 32 classes distintas de folhas.

1.2. Quantidade de imagens por classe e distribuição de classes

A Tabela 1 apresenta o detalhamento da quantidade absoluta de imagens e a respectiva porcentagem de representatividade para cada uma das 32 classes da base de dados.

Tabela 1: Quantidades

Classe	Qtd.	%	Classe	Qtd.	%	Classe	Qtd.	%
classe 0	59	3,11%	classe 11	63	3,32%	classe 22	55	2,90%
classe 1	63	3,32%	classe 12	52	2,74%	classe 23	65	3,43%
classe 2	65	3,43%	classe 13	65	3,43%	classe 24	54	2,85%
classe 3	72	3,80%	classe 14	60	3,17%	classe 25	52	2,74%
classe 4	73	3,85%	classe 15	56	2,96%	classe 26	53	2,80%
classe 5	56	2,96%	classe 16	77	4,06%	classe 27	55	2,90%
classe 6	62	3,27%	classe 17	62	3,27%	classe 28	57	3,01%
classe 7	52	2,74%	classe 18	61	3,22%	classe 29	64	3,38%
classe 8	55	2,90%	classe 19	66	3,48%	classe 30	53	2,80%
classe 9	59	3,11%	classe 20	60	3,17%	classe 31	56	2,96%
classe 10	50	2,64%	classe 21	55	2,90%			

1.3. Se o conjunto tá balanceado:

O conjunto de dados apresenta um leve desbalanceamento, contudo permanece em uma proporção bastante aceitável para o processo de treinamento e validação.

A classe de maior representatividade **Classe 16** é composta por 77 imagens 4,06% do total, ao passo que a classe de menor representatividade **Classe 10** reúne 50 imagens 2,64%. Embora a maior classe contenha 54% a mais de amostras em relação à menor, essa variação é considerada de reduzido impacto, não

gerando um viés significativo na acurácia dos classificadores.

2. Tabela de resultados (média $\pm$ desvio padrão):

Tabela 2: Resultados

Combinação	Classificador	Acurácia	Sensibilidade	Especificidade	F1-score
GLCM + Forma	KNN	84,27% $\pm$ 1,37%	83,55% $\pm$ 1,41%	99,49% $\pm$ 0,05%	83,16% $\pm$ 1,47%
	Gaussian NB	81,80% $\pm$ 0,73%	81,01% $\pm$ 0,70%	99,41% $\pm$ 0,02%	80,45% $\pm$ 0,67%
	MLP	91,66% $\pm$ 1,17%	91,45% $\pm$ 1,21%	99,73% $\pm$ 0,04%	91,42% $\pm$ 1,13%
	SVM RBF	85,05% $\pm$ 0,71%	84,45% $\pm$ 0,75%	99,52% $\pm$ 0,02%	83,93% $\pm$ 0,82%
LBP + Forma	KNN	88,36% $\pm$ 0,97%	87,87% $\pm$ 1,05%	99,62% $\pm$ 0,03%	87,62% $\pm$ 1,03%
	Gaussian NB	83,22% $\pm$ 1,43%	82,42% $\pm$ 1,50%	99,46% $\pm$ 0,05%	82,00% $\pm$ 1,42%
	MLP	93,81% $\pm$ 1,00%	93,58% $\pm$ 1,00%	99,80% $\pm$ 0,03%	93,60% $\pm$ 1,03%
	SVM RBF	87,00% $\pm$ 1,50%	86,45% $\pm$ 1,65%	99,58% $\pm$ 0,05%	86,20% $\pm$ 1,76%
Hu + Forma	KNN	76,09% $\pm$ 1,25%	75,17% $\pm$ 1,26%	99,23% $\pm$ 0,04%	74,66% $\pm$ 1,30%
	Gaussian NB	71,58% $\pm$ 3,52%	70,91% $\pm$ 3,30%	99,10% $\pm$ 0,11%	69,66% $\pm$ 3,20%
	MLP	87,47% $\pm$ 1,36%	87,10% $\pm$ 1,42%	99,60% $\pm$ 0,04%	87,12% $\pm$ 1,46%
	SVM RBF	79,81% $\pm$ 1,45%	79,03% $\pm$ 1,60%	99,35% $\pm$ 0,05%	78,39% $\pm$ 1,75%

A Tabela 2 apresenta o desempenho médio dos classificadores, acompanhado dos respectivos desvios padrões, para as métricas de Acurácia, Sensibilidade, Especificidade e F1-score.

A partir dos resultados obtidos, destacam-se os seguintes pontos:

- **Melhor Combinação do Experimento:** A rede neural **MLP** combinada ao extrator **LBP + Forma** obteve os índices mais elevados do estudo, alcançando 93,81% $\pm$ 1,00% de acurácia e 93,60% $\pm$ 1,03% de F1-score.
- **Eficiência dos Extratores:** A extração baseada em **LBP + Forma** provou ser a mais representativa para o problema, superando a combinação **GLCM + Forma** em todos os classificadores. Os **Momentos de Hu + Forma** apresentaram o desempenho mais modesto, registrando uma queda expressiva de desempenho em relação aos outros descritores.
- **Hierarquia dos Classificadores:** Observou-se uma consistência na ordem de eficácia dos modelos em todos os cenários: MLP > SVM (RBF) > KNN > Gaussian NB. Além disso, a métrica de **Especificidade** manteve-se elevada em todas as configurações ($\geq 99,10\%$), indicando baixa taxa de falsos positivos no conjunto de dados.

3. Análise de erros

A Tabela 3 apresenta o quantitativo absoluto de classificações incorretas efetuadas por cada algoritmo, considerando os diferentes conjuntos de atributos avaliados no experimento.

Tabela 3: Quantidade total e parcial de erros por classificador.

Classificador	GLCM + Forma	LBP + Forma	Hu + Forma	Total de Erros
MLP	159	118	238	515
SVM (RBF)	285	247	385	917
KNN	300	222	455	977
Gaussian NB	337	320	460	1.117

Com o objetivo de avaliar a precisão e a capacidade de generalização dos algoritmos testados, contabilizou-se o quantitativo absoluto de classificações incorretas obtidas por cada modelo em relação às três combinações de atributos (*GLCM + Forma*, *LBP + Forma* e *Momentos de Hu + Forma*).

No cômputo geral, a rede neural **MLP** destacou-se com a maior assertividade, registrando o menor número acumulado de falhas (**515 erros**), seguida pelo **SVM (RBF)** com **917 erros**, pelo **KNN** com **977 erros** e, por fim, pelo **Gaussian Naive Bayes**, que apresentou o maior volume de equívocos (**1.117 erros**).

Analisando o impacto dos descritores de características, observa-se um padrão claro: a combinação **LBP + Forma** foi consistentemente a mais discriminativa, minimizando os erros em todos os classificadores. Em contrapartida, o uso isolado dos **Momentos de Hu + Forma** resultou nas maiores taxas de sobreposição e ambiguidade entre as classes foliares.

3.1. Quais classes foram mais confundidas:

A Tabela 4 resume os pares de classes que geraram a maior quantidade de erros de classificação em cada modelo e extrator de atributos.

Tabela 4: Pares de classes com maior número de confusões por algoritmo.

Classificador	Extrator de Atributos	Maior Confusão (Par de Classes)	Nº de Erros
KNN	GLCM + Forma	28 – 14 e 25 – 24	18
	LBP + Forma	30 – 29	9
	Hu + Forma	24 – 6	12
Gaussian NB	GLCM + Forma	0 – 20	18
	LBP + Forma	10 – 13 e 23 – 24	14
	Hu + Forma	13 – 12 21 – 9	26 22
MLP	GLCM + Forma	24 – 25	7
	LBP + Forma	13 – 11 e 8 – 6	5
	Hu + Forma	24 – 25 e 0 – 20	9
SVM (RBF)	GLCM + Forma	0 – 20	25
	LBP + Forma	8 – 6, 25 – 28 e 10 – 13	9
	Hu + Forma	24 – 6 e 15 – 14	16

A partir da análise dos dados da Tabela 4, destacam-se alguns comportamentos relevantes quanto ao desempenho dos modelos e extratores:

- **Invariância de Forma e Limitações do Hu:** O maior pico de erros registrado no experimento ocorreu com o extrator *Momentos de Hu + Forma* no algoritmo Gaussian Naive Bayes, gerando 26 confusões entre as classes 13 e 12, e 22 confusões entre as classes 21 e 9. Isso evidencia que apenas descritores de forma/momentos não são suficientes para discriminar certas classes botânicas que possuem geometria similar.
- **Ambiguidades Recorrentes (Classes 0–20):** O par de classes 0 e 20 apresentou forte sobreposição ao utilizar o extrator *GLCM + Forma*, registrando 18 confusões no Gaussian NB e atingindo 25 erros no SVM (RBF). Esse padrão indica que a microtextura e a forma dessas duas classes compartilham valores de atributos muito próximos.
- **Superioridade do MLP:** Em contrapartida, a rede neural MLP demonstrou alta capacidade de generalização e separação de classes. Mesmo em seus piores cenários de confusão, o volume máximo de erros foi de apenas 9 ocorrências, reforçando a eficácia do modelo para este problema de classificação.

3.2. Análise do Desempenho das Combinações e dos Classificadores:

Com base nos resultados da Tabela 2 e na análise de falhas apresentada na Seção 3.1, destacam-se as seguintes conclusões sobre o desempenho dos extratores e dos classificadores:

- **Desempenho das Combinações de Atributos:** A combinação **LBP + Forma** obteve a **melhor performance global**, sendo superior em todas as métricas para os quatro classificadores e registrando o menor número de erros acumulados. O conjunto **GLCM + Forma** apresentou o segundo melhor resultado de forma consistente. Por outro lado, a combinação **Momentos de Hu + Forma** demonstrou o **pior desempenho**, mantendo médias de acurácia predominantemente abaixo de 80% e exibindo maior variância (desvio padrão elevado), o que reflete uma menor estabilidade na representação das características foliares.
- **Dificuldades dos Classificadores:** O modelo **Gaussian Naive Bayes** registrou a **maior dificuldade** de aprendizado, sendo o responsável pelo maior volume absoluto de classificações incorretas 1.117 erros no total e pelas piores médias de F1-score. O algoritmo **KNN** também apresentou limitações expressivas, acumulando 977 falhas. Em contrapartida, o modelo **MLP** exibiu a melhor capacidade de generalização 515 erros, seguido pelo **SVM (RBF)** 917 erros.

3.3. Exemplos de imagens classificadas incorretamente:

3.3.1. KNN

GLCM + Forma



(a) Classe 14 (confundida com 28).



(b) Classe 28 (confundida com 14).

Figura 1: À esquerda, folha da classe 14 classificada erroneamente como 28; à direita, folha da classe 28 confundida com a classe 14. Motivo do erro: As duas folhas têm o formato e o desenho da superfície muito parecidos, fazendo o KNN achar que uma era vizinha da outra no gráfico.

LBP + Forma



(a) Classe 29 (confundida com 30).



(b) Classe 30.

Figura 2: À esquerda, folha da classe 29 classificada erroneamente como classe 30; à direita, folha da classe 30 (não houve confusão inversa da classe 30 com 29). Motivo do erro: Os detalhes da textura das duas folhas são quase idênticos, confundindo a contagem de vizinhos do algoritmo.

Momentos de Hu + Forma




Figura 3: À esquerda, folha da classe 6 classificada erroneamente como 24; à direita, folha da classe 24 confundida com classe 6. Motivo do erro: O contorno e a silhueta das duas folhas são praticamente iguais, e o extrator de Hu olha só para o formato geral.

3.3.2. Gaussian Naive Bayes

GLCM + Forma




Figura 4: À esquerda, folha da classe 0 classificada erroneamente como 20; à direita, folha da classe 20 confundida com classe 0. Motivo do erro: O algoritmo assume que textura e formato não têm relação entre si, além de as folhas serem muito compridas e finas.

LBP + Forma




Figura 5: À esquerda, folha da classe 10 classificada erroneamente como 13; à direita, folha da classe 13 confundida com classe 10. Motivo do erro: Formato e textura muito parecidos entre as duas classes, fazendo o cálculo de probabilidade do Naive Bayes errar a escolha.

Momentos de Hu + Forma




Figura 6: À esquerda, folha da classe 12 classificada erroneamente como 13; à direita, folha da classe 13 confundida com classe 12. Motivo do erro: As duas folhas têm formato oval/alongado muito parecido, e os Momentos de Hu não conseguem ver diferenças pequenas.

3.3.3. MLP

GLCM + Forma




Figura 7: À esquerda, folha da classe 24 classificada erroneamente como 25; à direita, folha da classe 25 confundida com classe 24. Motivo do erro: As bordas das folhas são quase idênticas e a textura GLCM não trouxe detalhe suficiente para a rede neural separar as duas.

LBP + Forma




Figura 8: À esquerda, folha da classe 11 classificada erroneamente como 13; à direita, folha da classe 13 confundida com classe 11. Motivo do erro: Mesmo usando o LBP, o tamanho e o padrão das nervuras dessas duas folhas são tão próximos que a rede confundiu.

Momentos de Hu + Forma




Figura 9: À esquerda, folha da classe 24 classificada erroneamente como 25; à direita, folha da classe 25 confundida com classe 24. Motivo do erro: Como os Momentos de Hu só olham o contorno geral, a rede neural não teve informação suficiente sobre a textura para não errar.

3.3.4. SVM com kernel RBF

GLCM + Forma




Figura 10: À esquerda, folha da classe 0 classificada erroneamente como 20; à direita, folha da classe 20 (não houve confusão inversa da classe 20 com 0). Motivo do erro: A folha ficou bem na "linha de fronteira" que o SVM desenhou para separar as classes, por causa da forma e textura muito parecidas..

LBP + Forma




Figura 11: À esquerda, folha da classe 6 classificada erroneamente como 8; à direita, folha da classe 8 confundida com classe 6. Motivo do erro: O formato das folhas e o padrão de superfície são tão parecidos que o SVM colocou as duas no mesmo grupo.

Momentos de Hu + Forma




Figura 12: À esquerda, folha da classe 6 classificada erroneamente como 24; à direita, folha da classe 24 confundida com classe 6. Motivo do erro: Os dados de contorno das duas classes são quase iguais, então o SVM não conseguiu criar uma margem de separação entre elas.

3.4. Possíveis causas dos erros:

A partir da análise dos exemplos de imagens erroneamente classificadas (Seção 3.3) e da matriz de erros observada (Tabelas 3 e 4), foi possível identificar três fatores principais que influenciaram diretamente os equívocos cometidos pelos algoritmos:

- **Alta Similaridade Morfológica Interclasses (Geometria e Contorno):** Diversas classes distintas apresentam geometrias, proporções de aspecto e contornos extremamente semelhantes. Por exemplo, as folhas da Classe 0 e da Classe 20 possuem formatos lanceolados/alongados praticamente idênticos. Nesses cenários, extratores que dependem fortemente de

contorno ou invariância geométrica (como os Momentos de Hu) falham em encontrar fronteiras de separação nítidas, resultando no expressivo pico de confusões observado em modelos como o Gaussian Naive Bayes.

- **Ambiguidade na Textura Foliar e Limitações do Descritor GLCM:**

Embora a textura seja um elemento discriminativo relevante, a combinação GLCM + Forma apresentou falhas ao diferenciar classes cujas nervuras e padrões de microtextura são visualmente muito próximos (como nos pares 24–25 e 0–20). Como a GLCM captura estatísticas espaciais de segundo nível em escala global ou em direções fixas, ela se mostrou menos refinada que o LBP (*Local Binary Patterns*), que descreve microestruturas locais com maior detalhamento.

- **Premissas Estatísticas dos Classificadores:** A taxa de erro variou consideravelmente conforme a arquitetura dos algoritmos:

- **Gaussian Naive Bayes (1.117 erros):** Assume que os atributos seguem uma distribuição gaussiana e são independentes entre si. Essa suposição de independência falha em conjuntos de dados onde atributos de textura e forma possuem forte correlação linear/não linear, levando a um baixo desempenho de generalização.
- **KNN (977 erros):** Por se basear puramente em distância no espaço de atributos, sofre quando há sobreposição de densidade entre classes, tornando-se sensível a ruídos ou pequenas variações de escala e iluminação.
- **MLP e SVM RBF (Menores taxas de erro):** Demonstraram maior capacidade para mapear fronteiras de decisão complexas e não lineares, sendo a rede MLP a que melhor lidou com as ambiguidades residuais dos descritores.